
Benchmark YOLOv11s su MIO-TCD

Localization — Report tecnico

Progetto: NGS2026

Data: 15 Maggio 2026

Dataset: MIO-TCD Localization (Miovision Traffic Camera Dataset)

Modello testato: yolov11s.hef (6 classi, NMS integrato, compilato per Hailo-8)

Hardware: Raspberry Pi 5 + Hailo-8 AI HAT+

1. Obiettivo

Validare il modello YOLOv11s vehicle detection (attualmente integrato nella pipeline NGS) su un dataset esterno con **vista parzialmente dall'alto**, per stimare la capacità di generalizzazione del modello su uno scenario simile al caso d'uso reale (camera a 2-3m di altezza, tipo semaforo). Questo benchmark colmava un buco metodologico: il modello era stato valutato finora solo sul test set del suo training (OpenImages v7) e mai su un dataset esterno con prospettiva diversa.

2. Scelta del dataset

Dopo ricerca, è stato scelto **MIO-TCD Localization**
(<https://tcd.miovision.com/challenge/dataset.html>):

- 137.743 immagini totali (110.000 train con GT pubbliche + 27.743 test senza GT)
- 11 classi: car, motorcycle, bus, articulated_truck, single_unit_truck, pickup_truck, work_van, bicycle, pedestrian, motorized_vehicle, non-motorized_vehicle
- Frame di videosorveglianza stradale nord-americana (USA/Canada)
- Vista zenitale o quasi-zenitale, immagini 640×480 di qualità medio-bassa
- GT in formato CSV (image_id, class_name, x1, y1, x2, y2)

Limitazione nota fin dall'inizio: dataset USA, distribuzione veicoli diversa dall'Italia (molti pickup, work van di tipo americano), qualità immagine compressa. Accettato come **stress test out-of-distribution**.

3. Metodologia

3.1 Mapping classi MIO-TCD modello NGS (6 classi)

MIO-TCD	Modello NGS
car	car
pickup_truck	pickup
articulated_truck + single_unit_truck	truck (unificate)
bus	bus
work_van	van
motorcycle	motorcycle
bicycle , pedestrian , non-motorized_vehicle , motorized_vehicle	IGNORE

3.2 Scenario di valutazione

Adottato **Scenario B (masking)**: le bbox di classi non mappabili (bicycle, pedestrian, non-motorized_vehicle, motorized_vehicle) vengono escluse dal matching IoU e non conteggiano né come TP né come FP. Le immagini complete del dataset sono comunque usate per simulare il rumore reale della scena.

Motivazione: motorized_vehicle è una classe di “veicoli non classificabili dall’annotatore” (occlusione, distanza), quindi è metricamente scorretto considerarla nel matching.

3.3 Metrica bonus

Per i 25.845 motorized_vehicle (veicoli ambigui), si calcola la percentuale di rilevazione come “veicolo di qualsiasi classe” ($\text{IoU} \geq \text{soglia}$, classe non vincolante). Questo misura il **vehicle recall generico**, indipendente dalla classificazione fine.

3.4 Setup tecnico

- **Letterboxing 640×640** con preservazione aspect ratio
- **Inferenza Hailo-8** via HailoRT, output HAILO NMS BY CLASS (NMS già integrato durante compilazione)
- **Score threshold:** 0.2 (già applicato internamente dall’NMS Hailo, coerente con benchmark plate detection precedenti)

- **IoU matching:** 0.3 (dopo test diagnostico — vedi sezione 5.2)
 - **Coordinate Hailo** in ordine y1, x1, y2, x2 (gestite esplicitamente)
 - **Matching greedy** convenzione COCO-like: predizione con classe corretta consuma la GT, predizione con classe sbagliata non consuma
-

4. Test 1 — Sample stratified (2.281 immagini)

4.1 Sampling

Stratified sampling per garantire potere statistico anche sulle classi rare (es. motorcycle, 1.837 bbox totali nel dataset):

Classe	Quota richiesta	Pool disponibile	Selezionate
car	500	~95.000	500
pickup	400	~28.500	400
truck	400	~12.500	400
bus	300	~7.000	300
van	300	~6.500	300
motorcycle	400	~1.500	400

Totale post-deduplicazione: **2.281 immagini uniche**, 9.965 bbox totali (di cui 9.061 mappabili e 904 ignorate).

4.2 Risultati sample con IoU = 0.5

Classe	Precision	Recall	F1	TP	FP	FN
bus	0.6043	0.2989	0.4000	142	93	333
car	0.5818	0.2588	0.3583	1.536	1.104	4.398
pickup	0.1915	0.0251	0.0444	27	114	1.047
truck	0.2805	0.0928	0.1395	62	159	606
van	0.4286	0.0066	0.0130	3	4	453

motorcycle	0.3395	0.2841	0.3094	129	251	325
OVERALL	0.5240	0.2096	0.2994	1.899	1.725	7.162

4.3 Risultati sample con IoU = 0.3

Classe	Precision	Recall	F1
bus	0.6511	0.3221	0.4310
car	0.6711	0.2971	0.4119
pickup	0.2143	0.0279	0.0494
truck	0.3348	0.1108	0.1665
van	0.4286	0.0066	0.0130
motorcycle	0.3588	0.2996	0.3265
OVERALL	0.5982	0.2383	0.3408

L'abbassamento della soglia IoU da 0.5 a 0.3 migliora il recall solo di 2-4 punti percentuali. Questo esclude che il problema sia "bbox quasi corrette ma con IoU borderline". Le predizioni mancano proprio, oppure sono classificate male.

5. Test 2 — Run completo (110.000 immagini, IoU 0.3)

5.1 Risultati

Classe	Precision	Recall	F1	TP	FP	FN
bus	0.6367	0.3151	0.4215	3.339	1.905	7.259
car	0.7129	0.3555	0.4744	83.016	33.439	150.481
pickup	0.3320	0.0329	0.0599	1.457	2.931	42.826
truck	0.3009	0.1143	0.1657	1.720	3.996	13.322
van	0.3237	0.0168	0.0319	146	305	8.563
motorcycle	0.0466	0.3152	0.0812	579	11.852	1.258

OVERALL	0.6238	0.2875	0.3936	90.257	54.428	223.709
---------	--------	--------	--------	--------	--------	---------

5.2 Metrica bonus

Sui 25.845 `motorized_vehicle` (veicoli ambigui in GT), il modello ne ha rilevati come veicolo solo **2.205 (8.5%)**.

6. Analisi dei risultati bassi

6.1 Domain shift massivo training/test

Il modello è stato addestrato su **OpenImages v7**: foto di alta qualità, scattate da terra, vista laterale/frontale, veicoli grandi e ben definiti. MIO-TCD è un dataset radicalmente diverso:

- Frame compressi di videosorveglianza
- Risoluzione 640×480
- Veicoli spesso piccolissimi (10-30 pixel)
- Vista zenitale estrema (camere su pali a 5-10m, ben oltre i 2-3m del caso NGS)
- Distribuzione veicoli USA/Canada

Il gap tra training e test è massimo. Sul test set OpenImages originale (vista normale) il modello faceva **F1 ~0.71**; qui scende a **F1 ~0.39 overall**.

6.2 Vista zenitale cancella le caratteristiche distintive

Le classi `pickup` e `van` collassano drasticamente:

- Pickup: recall 3.3% sul full (predizioni 1.457 / GT 44.283)
- Van: recall 1.7% sul full (predizioni 146 / GT 8.709)

Dall'alto un pickup appare come "auto con tetto piatto" e un van come "parallelepipedo". Le feature che il modello ha appreso su OpenImages (cassone del pickup, profilo laterale del van, finestrini) sono invisibili in vista zenitale. Tutto viene classificato come `car`.

6.3 Motorcycle: precision crolla sul full dataset

Sul sample: precision motorcycle 34%, sul full: **4.7%** (579 TP su 12.431 predizioni totali). Il modello classifica come "motorcycle" molte cose che non lo sono (verosimilmente bici, pedoni, oggetti piccoli in lontananza, ombre allungate). Sul sample stratified questo

problema era attenuato perché il sample era bilanciato e c'erano poche immagini con bici/pedoni; sul full la concentrazione di bici/pedoni emerge in pieno.

6.4 Quantizzazione INT8 come concausa

La compilazione HEF è stata fatta con `optimization level 0` (no GPU disponibile sul Mac di Federico) e calibrazione su 1.001 immagini. Su immagini molto diverse dal dominio di training questa quantizzazione approssimativa accentua il calo di performance. Una parte del gap (stimabile in 5-10 punti percentuali di F1) è attribuibile alla quantizzazione, il resto è generalizzazione strutturale.

6.5 Vehicle recall 8.5% conferma il problema base

La metrica bonus mostra che il modello fatica anche solo a “vedere che c'è un veicolo” su MIO-TCD: solo 2.205 dei 25.845 veicoli ambigui (`motorized_vehicle`) vengono rilevati come qualsiasi cosa. Il problema non è solo classificazione fine, è proprio detection.

7. Conclusioni

7.1 Cosa abbiamo imparato

- Il modello YOLOv11s **non generalizza** su dataset out-of-distribution con:
 - Qualità immagine bassa (videosorveglianza compressa)
 - Vista zenitale estrema (camera molto alta)
 - Distribuzione veicoli diversa da quella di training
- Le classi `pickup` e `van` sono particolarmente fragili: dall'alto vengono confuse sistematicamente con `car`
- Motorcycle ha alta variabilità di precision tra dataset: solido su sample bilanciato, rumoroso su dataset con molti pedoni/bici

7.2 Cosa NON concludere

- **Il modello non è “rotto”**. Sul test set OpenImages (vista normale, in-distribution) faceva $F1 = 0.71$. Su MIO-TCD non sta facendo male per un bug, sta facendo male perché siamo molto fuori dal suo dominio.
- **Non significa che vada buttato e riaddestrato da zero**. Il caso d'uso NGS reale (camera 2-3m su semaforo, ambiente italiano, qualità decente) è drasticamente meno estremo di MIO-TCD.

7.3 Il numero che conta

MIO-TCD rappresenta un **floor di generalizzazione**: il peggio che il modello può fare su dati molto distanti dal training. Il caso operativo reale NGS è ragionevolmente atteso essere meglio di così, ma quanto meglio resta da misurare.

8. Alternative e prossimi passi

8.1 Strada 1 — Benchmark su video reali del caso operativo (raccomandato)

Esiste già un video del parcheggio italiano usato per validare qualitativamente la pipeline. Annotando manualmente 100-200 frame con Label Studio o CVAT (2-3 ore di lavoro), si può lanciare lo stesso script di benchmark e ottenere **numeri rappresentativi del caso d'uso reale**. Questi sono i numeri da portare in call.

Una tabella tipo:

Dataset	Scenario	F1 OVERALL	Note
OpenImages v7 test	Training-domain, vista normale	0.71	Baseline
Parcheggio italiano (da annotare)	Caso operativo reale	?	Da misurare
MIO-TCD (full, 110k img)	Out-of-distribution worst-case	0.39	Stress test

è quella che vende in call e dà a NGS una stima onesta delle aspettative reali.

8.2 Strada 2 — Fine-tuning su dataset europeo stradale

Se la performance sul caso reale italiano risultasse insufficiente, esistono dataset europei che potrebbero essere usati per fine-tuning:

- **UA-DETRAC** (Cina, sorveglianza stradale, vista parzialmente zenitale): molto più vicino al caso NGS rispetto a MIO-TCD
- **Cityscapes** (Germania, vista guida): foto di qualità, prospettiva stradale
- **KITTI** (Germania, vista guida): standard accademico

Il fine-tuning richiederebbe 1-2 giornate di GPU (Colab o Tesla T4) e ricompilazione HEF.

8.3 Strada 3 — Estendere il dataset di training attuale

Includere immagini con vista parzialmente zenitale in OpenImages v7 (la query “traffic camera”, “intersection from above”, ecc.) e ri-addestrare il modello small. È la strada più radicale ma anche quella che produce un modello più robusto per il caso d’uso NGS.

8.4 Strade NON consigliate

- **Continuare a sbattere contro MIO-TCD** non porta valore: il dataset è strutturalmente troppo diverso dal caso d’uso, non rappresenta lo scenario operativo.
 - **Buttare il modello e ricominciare** sarebbe sproporzionato: il modello sul suo dominio funziona, va solo validato e (forse) raffinato sul dominio operativo reale.
-

9. Stato del benchmark MIO-TCD

Dataset scaricato e ispezionato

Sampling stratified implementato e testato (2.281 immagini)

Pipeline di benchmark implementata e validata

Run su sample (IoU 0.5 e 0.3) completati

Run su full dataset 110.000 immagini completato (IoU 0.3)

Risultati salvati in `/home/pi/mio_tcd_results_full/` (CSV predizioni, CSV metriche, esempi visivi di FP/FN per classe)

Output disponibili:

- `predictions.csv` — 144.685 predizioni con tag TP/FP/MASKED
- `metrics_per_class.csv` — metriche aggregate per classe
- `errors_sample/<classe>/` — esempi visivi di FP e FN per ispezione qualitativa
- `benchmark_report.md` — report markdown auto-generato