

NGS2026 — Benchmark Preprocessing OCR

New Generation Sensors · Edge AI Pipeline · Maggio 2026

Sintesi

Questo report documenta il benchmark di preprocessing pre-OCR su EasyOCR, eseguito sul dataset European License Plates utilizzato anche nel precedente report (EasyOCR vs Gemini API). L'obiettivo era verificare se tecniche di image processing applicate prima della lettura OCR potessero ridurre la differenza di performance tra EasyOCR (16.7% exact match nel report precedente) e Gemini Flash (81.2%).

Il documento e' strutturato per essere esteso con capitoli successivi. Il capitolo 1 contiene il primo screening su 50 immagini, il capitolo 2 (da aggiungere) conterra' i risultati del run completo sulle 735 immagini con metriche aggiuntive (substring match e post-processing automatico).

Capitolo 1 — Screening preprocessing (8 varianti, 50 immagini)

1.1 Setup

Sono state testate 8 varianti di preprocessing applicate a 50 immagini campione del dataset European License Plates. Tutte le varianti utilizzano lo stesso engine EasyOCR con allowlist A-Z + 0-9, gpu disabilitato (RPi5).

#	Variante	Descrizione
1	baseline_raw	Immagine originale, nessun preprocessing (controllo)
2	baseline_resize_4x	Solo upscaling bicubico 4x
3	grayscale	Conversione a scala di grigi
4	gray_clahe	Grayscale + CLAHE (contrasto adattivo)
5	gray_clahe_sharpen	CLAHE + unsharp masking (rimarca bordi)
6	adaptive_threshold	Binarizzazione adattiva (puro bianco/nero)
7	gray_clahe_threshold	CLAHE + threshold adattivo
8	upscale_gray_clahe	Upscaling 4x + grayscale + CLAHE

Parametri tecnici

CLAHE: clipLimit=2.0, tileGridSize=(8,8). Adaptive threshold: blockSize=15, C=5, metodo Gaussian. Upscaling: fattore 4x con interpolazione bicubica. Unsharp masking: Gaussian blur sigma=2.0, blend 1.5/-0.5.

1.2 Risultati screening

Classifica delle varianti ordinate per exact match rate. Tutti i valori sono calcolati sulle stesse 50 immagini.

#	Variante	Exact	Avg CER	Median CER	Tempo medio
1	baseline_raw	16.0%	1.086	0.333	1197 ms
2	gray_clahe	16.0%	1.102	0.354	1010 ms
3	grayscale	12.0%	1.079	0.333	1008 ms
4	gray_clahe_sharpen	12.0%	1.087	0.286	1097 ms

5	upscale_gray_clahe	12.0%	1.227	0.429	12275 ms
6	adaptive_threshold	8.0%	1.155	0.375	1113 ms
7	gray_clahe_threshold	4.0%	1.198	0.500	1426 ms
8	baseline_resize_4x	2.0%	1.250	0.464	11583 ms

Verde: top 2 varianti. Rosso: peggiori 2 varianti.

1.3 Osservazioni

Nessun preprocessing porta a miglioramenti significativi

Le 4 migliori varianti (baseline_raw, gray_clahe, grayscale, gray_clahe_sharpen) sono essenzialmente equivalenti, oscillando tra il 12% e il 16% di exact match. La variante senza preprocessing (baseline_raw) e' alla pari con la migliore preprocessing (gray_clahe). Questo suggerisce che il preprocessing applicato al crop targa non e' la leva che limita le performance di EasyOCR su questo dataset.

Le tecniche aggressive degradano i risultati

Le varianti con binarizzazione (adaptive_threshold, gray_clahe_threshold) scendono a 4-8%. Il motivo e' che la binarizzazione perde informazione utile (sfumature, anti-aliasing dei caratteri) e fa scattare confusioni che con la scala di grigi non si verificavano. Conferma una regola pratica: i moderni OCR neurali come EasyOCR preferiscono immagini naturali a immagini drasticamente processate.

Upscaling 4x e' troppo costoso senza beneficio

Le varianti che usano upscaling (baseline_resize_4x, upscale_gray_clahe) impiegano ~12 secondi per immagine contro 1 secondo delle altre, senza migliorare l'accuratezza (anzi, peggiorano leggermente). EasyOCR su immagini grandi e' molto piu' lento, ma il ridimensionamento bicubico non aggiunge informazione reale che il modello possa sfruttare.

1.4 Il problema del Character Error Rate sopra 1.0

Tutte le varianti mostrano un avg CER vicino o sopra a 1.0, mentre la median CER e' intorno a 0.30-0.50. Questa discrepanza e' rivelatrice:

CER > 1.0 significa che la distanza di edit (Levenshtein) e' maggiore della lunghezza della GT. In termini pratici: **l'OCR sta producendo predizioni piu' lunghe della targa**, perche' legge anche testo extra non appartenente alla targa.

Questo dato e' stato confermato visivamente analizzando i CSV delle predizioni (vedi sezione successiva).

Capitolo 1 bis — Analisi degli errori di EasyOCR

Esaminando manualmente il CSV dei risultati di baseline_raw (50 immagini), e' emerso un pattern preciso degli errori che spiega perche' il preprocessing dell'immagine non aiuta. Sono state identificate 6 categorie di errori, ognuna con caratteristiche e implicazioni operative diverse.

2.1 Distribuzione delle categorie di errore

Distribuzione delle 50 predizioni di baseline_raw classificate per tipologia:

Categoria	N° casi	%	Note
Exact match (corretto)	8	16.0%	Predizione identica alla GT
GT contenuta in pred	10	20.0%	Targa letta + rumore intorno
Errori carattere puri	6	12.0%	Stessa lunghezza, caratteri sbagliati
Pred troncata	7	14.0%	OCR ha letto solo parte della targa
Pred contenuta in GT	1	2.0%	OCR ha letto un sottoinsieme
Predizione fuori target	18	36.0%	Errori multipli, difficili da recuperare
Predizione vuota	0	0.0%	Nessun output

Verde: predizioni gia' corrette. Giallo: targa letta correttamente ma con rumore intorno (recuperabile con post-processing).

2.2 Insight chiave: il 36% dei casi e' recuperabile

Sommando le categorie **exact match (16%)** e **GT contenuta in pred (20%)**, in **36% dei casi EasyOCR ha letto correttamente la targa**. La differenza fra le due categorie e' solo che nel secondo caso ha aggiunto caratteri extra intorno (codice paese, nome rivenditore, numeri di telefono, ecc.).

Questo cambia radicalmente l'interpretazione del benchmark precedente. EasyOCR non e' intrinsecamente debole sulle targhe europee come suggeriva il 16.7%: e' debole nel **delimitare** la targa dal contesto. Su un dataset di crop strettamente delimitati (o con post-processing efficace), il vero limite di accuratezza e' molto piu' alto.

2.3 Esempi concreti dai dati

Esempi reali tratti dai CSV (baseline_raw), che illustrano i diversi tipi di errore:

Ground Truth	Predizione EasyOCR	Categoria
00LH2877	IRL00HLH2877WWBKMOTORSELEHYUNDAI	GT contenuta + rumore massivo
0310CRG	CAT0310CRG	Prefisso paese aggiunto
08BBJ9	NL08BBJ9	Prefisso paese aggiunto
04WH3753	ANIARMHIIRL04NH3753	Rumore + errore carattere
07KE10361	CILLDARAIRL07KE10361MAXWELLMOTORSTATHYLTDELA005914863116	Rumore + telefono concessionario
1484ZM30	1484ZM30	Exact match (uno dei correttamente letti)
1484ZM30	14842M30	Errore carattere puro (Z -> 2)
1500WD68	50C68	Predizione troncata, lettura parziale
1AAL547	B1AAL547	Carattere extra in testa

2.4 Tipologie di rumore identificate

Il rumore aggiunto da EasyOCR non e' casuale: rientra in pattern riconoscibili tipici delle targhe e dei contesti automotive europei.

- Codice paese in testa.** Banda blu sinistra delle targhe UE (IRL, NL, DE, F, I, ecc.). Esempi: IRL00LH2877, NL08BBJ9, CAT0310CRG.
- Nome regione/provincia.** Targhe con riferimenti geografici sotto la targa principale. Esempi: CIARRAIIRL (Ciarrai = Kerry), CILLDARA (Kildare).
- Nome rivenditore/concessionario.** Stampe pubblicitarie attorno alle targhe nei dataset di vendita. Esempi: WWWBKMOTORSELEHYUNDAI, MAXWELLMOTORSTATHYLT.D.
- Numeri di telefono.** Numeri di telefono dei concessionari letti integralmente. Esempio: TELA0059148631465 (anche il prefisso internazionale).
- Lunghezza del rumore extra.** Su 10 casi di 'GT contenuta in pred', il rumore extra varia da 1 a 48 caratteri. Distribuzione: 4 casi con 1 char extra, 1 con 2, 3 con 3, 1 con 4, 1 outlier a 48.

2.5 Errori carattere classici (categoria 'errori puri')

Le 6 predizioni con stessa lunghezza ma caratteri diversi mostrano le confusioni tipiche dei modelli OCR su font targa. Riprendendo l'analisi del report precedente estesa al dataset corrente:

GT	Predetto	Esempio nel dataset
Z	2	1484ZM30 -> 14842M30
0	0	Confusione classica zero/lettera O
I	1	Confusione I maiuscola / 1
7	Z	Da report precedente, frequente in EasyOCR
4	L	Da report precedente, errore di forma
w	M	Errore strutturale su font compresso

Capitolo 1 ter — Conclusioni e prossimi passi

3.1 Conclusioni dello screening

- Il preprocessing dell'immagine pre-OCR **non e' la leva principale** per migliorare EasyOCR su questo dataset. Le 4 varianti migliori sono statisticamente equivalenti.
- Il limite reale di EasyOCR e' la **delimitazione del testo targa rispetto al contesto**. Il modello sa leggere bene i caratteri, ma legge anche tutto cio' che gli sta intorno.
- Le varianti aggressive (binarizzazione, threshold) **peggiorano le performance**: EasyOCR e' addestrato su immagini naturali, non binarizzate.
- L'upsampling 4x e' **controproducente**: triplica il tempo di esecuzione senza migliorare l'accuratezza.
- Il **36% dei casi e' potenzialmente recuperabile** con post-processing efficace, contro il 16% di exact match osservato. Questo e' il margine di miglioramento accessibile senza cambiare modello.

3.2 Raccomandazioni operative

Per il dataset misto europeo (caso generico)

Usare **baseline_raw** o **gray_clahe** indifferentemente per il preprocessing (nessuna delle due porta vantaggi rispetto all'altra, ma sono entrambe veloci e non degradano). Sviluppare invece un **post-processing agnostico** che estragga la stringa piu' 'simile a targa' dalla predizione raw, usando criteri come mix lettere/cifre, lunghezza tipica e rimozione di codici paese noti.

Per il caso d'uso reale NGS (targhe italiane)

Sulle targhe italiane il post-processing diventa molto piu' efficace grazie al formato rigido **AA000AA**. Si puo' applicare una regex pattern come filtro post-OCR: se l'output di EasyOCR contiene una sottostringa che matcha `[A-Z]{2}[0-9]{3}[A-Z]{2}`, quella e' la targa. Questa strategia rimuove automaticamente qualsiasi rumore di contesto (codici paese italiani come 'I' o 'IT', scritte di sfondo, ecc.).

Si stima che su targhe italiane la combinazione 'EasyOCR + regex AA000AA' possa portare l'accuratezza ben oltre il 50% (rispetto al 16% attuale su dataset misto), perche' la componente di rumore contestuale viene eliminata in modo deterministico.

3.3 Prossimi test pianificati

- Run completo su **735 immagini** con le 4 varianti migliori (baseline_raw, grayscale, gray_clahe, gray_clahe_sharpen) per confermare le tendenze osservate su un campione piu' grande.
- Aggiunta di metriche piu' significative: **substring_match** (la GT e' contenuta nella predizione?) e **exact_match_postproc** (la GT e' uguale alla predizione dopo post-processing automatico?).
- Test su **dataset di sole targhe italiane** (da reperire), per verificare l'efficacia del filtro pattern AA000AA e quantificare il guadagno rispetto al dataset misto.
- Eventuale valutazione di **alternative OCR** se EasyOCR anche con post-processing non raggiunge soglie operative accettabili (Tesseract con LSTM, Surya, TrOCR, ecc.).

Capitolo 2 (da aggiungere): risultati del run completo su 735 immagini con metriche estese (substring match, post-processing automatico) e classifica finale delle 4 varianti selezionate.